


# MACHINE LEARNING AND DNA SEQUENCING

黃紀琇

# CONTENT

- 1**    **introduction**
- 2**    **encode sequence data**
- 3**    **predict a gene family**
- 4**    **Predictions and result**
- 5**    **Subsequent Applications**





# INTRODUCTION

由A, T, C, G 組成

雙股螺旋

A與T相對，C與G相對

排列順序構成遺傳密碼，用來決定生命的遺傳表徵

# ENCODE SEQUENCE DATA

## ORDINAL VS ONE-HOT

|         | A         | C         | G         | T         | 差異        |
|---------|-----------|-----------|-----------|-----------|-----------|
| One-hot | [0,0,0,1] | [0,0,1,0] | [0,1,0,0] | [1,0,0,0] | 用於有順序性的資料 |
| Ordinal | 0.25      | 0.5       | 0.75      | 1         | 用於無順序性的資料 |

### Ordinal

- 將A, T, C, G改成序號0.25, 0.5, 0.75, 1
- 用LabelEncoder將A, T, C, G轉換0, 1, 2, 3
- 再用float\_encoded[float\_encoded == 0]的方法來將質改為0.25，以此類推

### One-hot

- 將“ATGC”轉成向量 [0,0,0,1]、[0,0,1,0]、[0,1,0,0]、[1,0,0,0]
- 當資料屬無序時更適合用one-hot做轉換，避免機器誤以為資料間有順序性
- 他無法轉換字串，需要先用LabelEncoder做轉換

# ENCODE SEQUENCE DATA - K-MER COUNTING

## k-mer counting

- 將輸入 DNA 序列依據指定大小 (k) 切割成重疊子字串 (k-mer)，並計算每個 k-mer 的出現次數。
- Example:  
Sequence: GTGCATCG, size = 3  
broken down into:  
GTG, TGC, GCA, CAT, TCG
- 將 DNA 序列轉為數值特徵，作為後續分類模型的輸入。
- 利用CountVectorizer 將序列視為句子，k-mer視為單詞

## k-mer counting Output:

Feature Names (詞彙表):

```
['aggtgc' 'aggttc' 'agtggg' 'caggtg' 'caggtt' 'cagtgg' 'ccaggt' 'cccagg'  
'gcaggt' 'gcccag' 'ggcagg' 'gggcag' 'ggtgcc' 'ggttca' 'gtgccc' 'gtgggc'  
'gttcag' 'tcagtg' 'tgccca' 'tgggca' 'ttcagt']
```

## 基因分類 ➤ 將切割後的單詞依基因家族分類

| Gene family                 | Number | Class label |
|-----------------------------|--------|-------------|
| G protein coupled receptors | 531    | 0           |
| Tyrosine kinase             | 534    | 1           |
| Tyrosine phosphatase        | 349    | 2           |
| Synthetase                  | 672    | 3           |
| Synthase                    | 711    | 4           |
| lon channel                 | 240    | 5           |
| Transcription factor        | 1343   | 6           |

# PREDICT A GENE FAMILY

- 使用 CountVectorizer  
() 創建 Bag of Words  
模型解析 DNA 序列數據
- k-mer 計算詞頻

## 特徵工程

- 選擇 Naive Bayes 作為基礎的初步模型
- 他對高維稀疏矩陣特別有效、訓練速度快。

## 模型訓練

- 運用 Confusion matrix, accuracy, precision, recall, f1 做評估

## 評估

## 原始資料

- 通過 Biopython 解析 DNA 序列數據

## 資料切分


- 運用 train\_test\_split()、交叉驗證
- 防止 overfitting 的核心步驟

## 預測

- 以 .predict() 展示

# HUMAN DNA PREDICTIONS

## CONFUSION MATRIX FOR HUMAN DNA PREDICTIONS




## 其他模型性能指標


```
--- Metrics for Human DNA Predictions ---  
accuracy = 0.984  
precision = 0.984  
recall = 0.984  
f1 = 0.984
```

- 根據我們對對人類的測試集進行預測，結果顯示我們的模型並沒有過度擬合訓練數據

# Cross-species Classification Performance



```
--- Metrics for Chimpanzee DNA Predictions ---  
accuracy = 0.993  
precision = 0.994  
recall = 0.993  
f1 = 0.993
```



```
--- Metrics for Dog DNA Predictions ---  
accuracy = 0.926  
precision = 0.934  
recall = 0.926  
f1 = 0.925
```

根據輸出來看，猩猩的數據比狗的好，這顯示猩猩的基因比狗的基因更接近人類

# SUBSEQUENT APPLICATIONS

## 後續技術升級

- 資料前處理：可加入 GC 含量、結構預測等生物特徵
- 模型優化：嘗試 ensemble、AutoML、超參數調整
- 特徵工程：測試不同的 k 值、詞袋轉 TF-IDF

## 後續應用

- 疾病相關基因分類
- 跨物種基因同源性預測

